

การประกันคุณภาพซอฟต์แวร์

# การเปรียบเทียบ การสร้างชุดทดสอบอัตโนมัติ บน Java Defects4J

IPO

MIO (EvoSuite)

DeepSeek

Gemini

CP353201 Software Quality Assurance • มหาวิทยาลัยขอนแก่น  
ผศ.ดร.ชิตสุธา สุ่มเล็ก • ภาคการศึกษา 1/2569

นายปวิศษ์ ประมวล 673380278-9 • นายแทนคุณ พันธุ์นิกุล 673380301-0  
นายธนภูมิ จันทรา 673380272-1 • นายศิษรินทร์ อุปจันทร์ 673380292-5

```
describe("Sum It Calculator", function() {
  it("adds the numbers", function() {
    var answer = sumit.add(2, 3);
    expect(answer).toEqual(5);
  });
  it("subtracts the numbers", function() {
    var answer = sumit.subtract(5, 2);
    expect(answer).toEqual(3);
  });
  it("multiplies the numbers", function() {
    var answer = sumit.multiply(2, 3);
    expect(answer).toEqual(6);
  });
  it("divides the numbers", function() {
    var answer = sumit.divide(6, 2);
    expect(answer).toEqual(3);
  });
});
```

# ขอบเขตและกระบวนการทดลอง

Defects4J คือ bugs จริงในโครงการ Java พร้อมโค้ดก่อนและหลังแก้บั๊ก



854 บั๊กใน 17 โครงการ × 4 เทคนิค = 3,416 คู่บั๊ก-เทคนิค



AVAILABLE\_EVALUATED 2,797 • NO\_SUITE 619 • รวม compile error จึงไม่ได้รันสำเร็จทุกคู่

# IPO ครอบคลุมทุกคู่ค่าที่กำหนด

Chart-14 • XYPlot.removeDomainMarker(index, marker, layer)

5 index x 2 marker x 2 layer

20 กรณี

10 กรณี

ครบ 24/24 คู่ค่า  
แสดง 4 จาก 10 กรณี

| index | marker | layer      |
|-------|--------|------------|
| 0     | 0.0    | FOREGROUND |
| 0     | 1.0    | BACKGROUND |
| 1     | 1.0    | FOREGROUND |
| 1     | 0.0    | BACKGROUND |

```
Object actual = new XYPlot().removeDomainMarker(
    0, new ValueMarker(0.0), Layer.FOREGROUND);
assertEquals("false", formatValue(actual));
```


ย่อจาก test จริง • false = ไม่มีเส้นถูกลบ • oracle จาก fixed version

277 class-level suites → ครอบคลุม 257 บั๊ก

Pairwise coverage ≠ code coverage ≠ fault detection

# MIO ค้นหา test ตามเป้าหมาย coverage

EvoSuite / MIO • budgets 30 / 60 / 120 วินาที • seeds 101 / 102 / 103



## 834 บั๊ก

มี suite เข้า benchmark  
พร้อม scaffolding

ทีมตั้งค่าการทดลอง รัน และเก็บหลักฐาน  
ใช้อัลกอริทึมค้นหาจาก EvoSuite

```
Document document0 = htmlTreeBuilder0.parse(...);
Element element0 = document0.body();
htmlTreeBuilder0.pushActiveFormattingElements(element0);
Element element1 = htmlTreeBuilder0
    .getActiveFormattingElement("body");
assertNotNull(element1);
assertEquals("colgroup", element1.baseUri());
```

... คือส่วนย่อ ไม่ใช่โค้ดพร้อมรัน

# Prompt เชื่อมกับ assertions ใน test

DeepSeek + Gemini ผ่าน KKU IntelSphere → JUnit4

Source + target +  
defect context เมื่อมี

KKU IntelSphere

DeepSeek / Gemini

JUnit4

DeepSeek / Closure-105

Java 8 / JUnit4

- package / imports ถูกต้อง
- exact value / state + boundary
- @Test(timeout=4000)


พฤติกรรมจริง  
["", "a"].join("+")  
expected "+a"  
buggy "a"

```
Node expr = joinCall(  
    array(string(""), string("a")), "+");  
assertEquals("+a", foldedString(expr));
```

helpers อยู่ใน suite จริง

เก็บ prompt, suite, token และเวลา  
บาง prompt ให้บริบท defect แก่โมเดล

# ใช้ suite เดียวกันตรวจ buggy และ fixed



Coverage รวม covered/total  
ของ target classes ต่อบั๊กก่อนหาค่าเฉลี่ย


FDR = detected/evaluated ที่มี suite  
รวม compile error แต่ไม่รวม NO\_SUITE

coverage ที่วัดไม่ได้  
ไม่ใช่ 0

# Gemini มี coverage เฉลี่ยสูงสุดในกลุ่มที่วัดได้

Line / Branch coverage (แกน 0–100%)

● Line ● Branch



86.29%  
Line

79.54%  
Branch

Line / Branch (%)

IPO (n=252) 26.76 / 18.67

MIO (n=797) 63.85 / 56.51

DeepSeek (n=192) 78.02 / 70.22

Gemini (n=424) 86.29 / 79.54

# Gemini ตรวจพบ 107 บั๊ก IPO มี FDR 14.40%


| เทคนิค | ตรวจพบ-ประเมิน | FDR | Compile error |
|--------|----------------|-----|---------------|
|--------|----------------|-----|---------------|

|          |         |        |         |
|----------|---------|--------|---------|
| IPO      | 37/257  | 14.40% | 5/257   |
| MIO      | 5/834   | 0.60%  | 37/834  |
| DeepSeek | 11/853  | 1.29%  | 661/853 |
| Gemini   | 107/853 | 12.54% | 429/853 |

รวม 144 บั๊กไม่ซ้ำ / 853 บั๊ก = 16.88%

853 บั๊กมี suite อย่างน้อยหนึ่งเทคนิค  
รวมผลตรวจพบเดิม ไม่ได้รัน ensemble ใหม่

NO\_SUITE ไม่อยู่ใน per-suite FDR • ตัวหารต่างกัน • snapshot 26 ก.ย. 2026



ตรวจพบ: IPO 37 MIO 5 DeepSeek 11 Gemini 107

# ข้อจำกัดจาก input, oracle และ environment

|     |                                                                      |                                  |
|-----|----------------------------------------------------------------------|----------------------------------|
| IPO | missing adapter / entrypoint<br>หรือ generation / verification error | เตรียม input + oracle            |
| MIO | dependency, compile, NPE, JVM crash, encoding                        | environment / tool compatibility |
| AI  | output compile fail                                                  | validate actual output           |



20 MIO • 1 DeepSeek • 1 Gemini

IPO 597 คู่: ไม่พร้อมสร้าง 560 และสร้าง/ยืนยันผิดพลาด 37  
การสร้างล้มเหลวกับ benchmark compile error เป็นคนละขั้นตอน

# Demo

2:30

ประเมิน suite จริงทั้ง 4 เทคนิค

>\_

.\scripts\demo\_four\_techniques.ps1

| เทคนิค / ตัวอย่าง      | Buggy fail | Fixed fail | ผลรอบก่อน    |
|------------------------|------------|------------|--------------|
| IPO / Chart-14         | 48         | 0          | BUG_DETECTED |
| MIO / Jsoup-45         | 0          | 0          | NOT_DETECTED |
| DeepSeek / Closure-105 | 2          | 0          | BUG_DETECTED |
| Gemini / Chart-3       | 2          | 0          | BUG_DETECTED |



# บทเรียนและหลักฐานสำหรับทำซ้ำ

## Coverage สูง

ต้องมี assertions ที่แยก buggy / fixed

README และ Docker

Source / tests / prompts / configuration

Results / logs

## อ่านผลร่วมกัน

FDR + compile error + suite ที่ขาด

Deliverables

รายงาน DOCX / PDF

คู่มือเดโม

master dataset

## ย้อนกลับได้

ทุกข้อสรุป → test / run log

[github.com/Bigzzz0/ProjectSQA](https://github.com/Bigzzz0/ProjectSQA)

# ขอบคุณครับ

# Configuration

Q&A only

IPO

Native pairwise • strength 2 • verified manifest 277 class suites / 257 bugs • fixed oracle

MIO

EvoSuite 1.0.6 / MIO • LINE:BRANCH • budgets 30/60/120s • seeds 101/102/103

AI


Java 8 / JUnit4 • @Test timeout 4000ms • deepseek-v4-flash / gemini-3.8-flash ผ่าน KKU IntelSphere

BENCHMARK

coverage / test command timeout 240s ต่อ step

ชื่อโมเดลเป็น identifier ในโครงการ IPO ไม่มี time budget ต่อบั๊กใน manifest  
Timeout ของ test method 4 วินาที ต่างจากคำสั่งประเมิน 240 วินาที

# ผลการสร้าง suite และต้นทุน



MIO: budget / coverage / n  
30s 65.73% n=1,023  
60s 68.73% n=1,015  
120s 70.82% n=989  
เวลาเฉลี่ย 68.29 / 90.62 / 194.41s

AI generation ต่อ record  
DeepSeek n=1,082  
21,045.26 tokens 295.54s  
Gemini n=1,079  
20,855.06 tokens 89.78s

กราฟแสดงแกน y 0–80% และใช้ค่าผล generation จริง  
Logs เชื่อม benchmark ไม่ครบ จึงไม่คำนวณ token ต่ออีกที่ตรวจพบ

# สาเหตุ NO\_SUITE

## IPO • 597 คู่

37 generation / verification error  
560 not ready = adapter 495 + entrypoint 47 + both 16 + adapter & not-pairwise-applicable 2

## MIO • 20 คู่

Mockito 15 dependency compile  
EvoSuite NPE: Math-13, Math-31, Gson-3  
Gson-8 JVM crash • JacksonDatabind-24 encoding compile


## DeepSeek 1 • Gemini 1

Math-13 target mismatch  
ไม่มี evaluable suite

หลักฐาน  
Combinatorial\_IPO/Results/generation\_manifest.json  
verified\_suites\_manifest.json  
MIO\_Algorithm/MIO\_FAILURE\_ANALYSIS\_REPORT.md  
results/suite\_gap\_audit.csv

Generation failure คือสถานะการสร้าง NO\_SUITE คือสถานะการส่งเข้า benchmark

# สถานะผลครบ 854 บั๊ก



ตรวจพบ / 854 บั๊ก

IPO 4.33%

MIO 0.59%

DeepSeek 1.29%

Gemini 12.53%

Coverage valid n

252 / 797 / 192 / 424

FLAKY\_OR REGRESSION หมายถึง fixed version ไม่ผ่าน ยังไม่ได้พิสูจน์ความไม่แน่นอนจากการรันซ้ำ  
แยก FDR ทั้งแค่ตัดลือกกับ FDR ต่อ suite ข้อมูล 26 กันยายน 2026

# วิธีทำซ้ำและหลักฐาน

1 README setup

2 start Docker

3 choose suite

4 runner buggy / fixed

5 master results

```
docker compose -f docker/docker-compose.yml up -d
docker exec defects4j_sqa defects4j info -p Math -b 2
.\scripts\demo_four_techniques.ps1
```

Outputs

results/master\_benchmark\_summary.csv  
results/master\_descriptive\_stats.json  
per-bug JSON • runID • hash • log

รายงาน: docs/final/SQA\_Final\_Report.docx และ .pdf

คู่มือเดโม: docs/demo/DEMO\_GUIDE.md

คำสั่ง benchmark เต็มอยู่ใน README

[github.com/Bigzzz0/ProjectSQA](https://github.com/Bigzzz0/ProjectSQA)

suites สร้างไว้แล้วสำหรับ live evaluation • reproduction ต้องใช้ environment และ dependencies จริง